Text Generation using RNN: Coding Exercise

Kyomin Jung

Department of Electrical and Computer Engineering Seoul National University



About Today Class

- Today's TA
 - □ 장윤아 (vn2209@snu.ac.kr)
 - □ 이동렬 (drl123@snu.ac.kr)



Contents

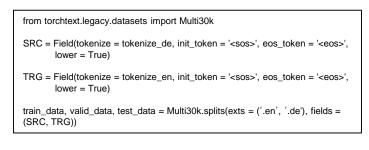
- Text generation using RNN & Attention
 - Practice
 - Load/preprocess data
 - Build Seq2Seq with attention model
 - Encoder
 - Attention
 - Decoder
 - Seq2Seq
 - Measure with BLEU
- Subword Tokenization
 - □ BPE (Byte Pair Encoding)
 - □ WordPiece
 - □ SentencePiece



- Multi30k Dataset
- 31014개 사진에 대해 설명하는 같은 뜻의 영어/독일어 문장 pair
- **■** Ex)
 - □ (En) Brick layers constructing a wall.
 - □ (De) Maurer bauen eine Wand.



Simple way of loading from PyTorch (using torchtext library):







Tokenizer

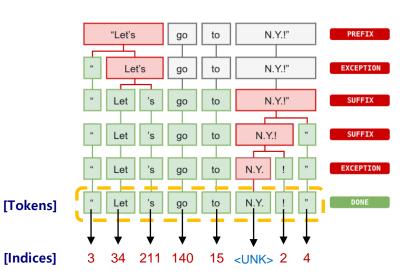
□ 언어별로 다른 tokenizer 적용

Create Source and Target Tokenizer

```
[3] spacy_de= spacy.load('de_core_news_sm')
    spacy_en = spacy.load('en_core_web_sm')

[4] tokenizer_de= get_tokenizer('spacy', language='de_core_news_sm')
    tokenizer_en= get_tokenizer('spacy', language='en_core_web_sm')

[5] tokenizer_en("he was bored")
    ['he', 'was', 'bored']
```



Special Tokens

- □ **<BOS>**, **<EOS>**: 문장의 시작, 끝을 나타내는 **token**
- □ <PAD>
- □ **<UNK>: OOV** 대응하기 위해 사용

Building Vocabulary

■ 언어별로 vocabulary 각각 생성 – from train dataset

```
from collections import Counter
from torchtext.vocab import vocab

counter_de = Counter()
counter_en = Counter()
for i in train_data:
    counter_en.update((i['src']))
    counter_de.update((i['trg']))

vocab_de = vocab(counter_de, min_freq=1, specials=('<unk>', '<BOS>', '<EOS>', '<PAD>'))
vocab_en = vocab(counter_en, min_freq=1, specials=('<unk>', '<BOS>', '<EOS>', '<PAD>'))
vocab_de.set_default_index(vocab_de['<unk>'])
vocab_en.set_default_index(vocab_en['<unk>'])
```

Torchtext.vocab.vocab

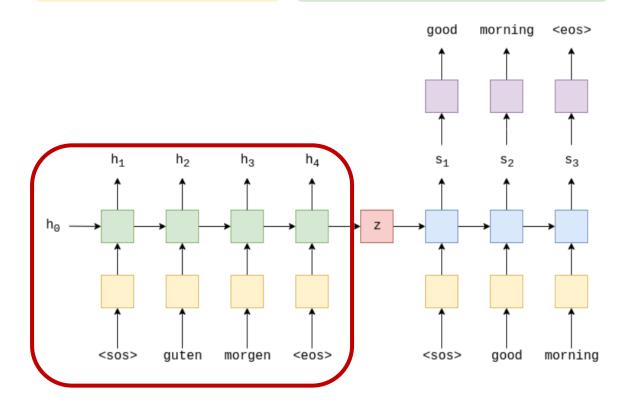
```
class torchtext.vocab.Vocab(counter, max_size=None, min_freq=1, specials=['<pad>'], vectors=None, unk_init=None, vectors_cache=None, specials_first=True)
```

- collections.Counter
 - □ 동일한 값의 자료가 몇 개인지 파악하는데 사용하는 객체

```
from collections import Counter
Counter('hello world')
# Counter({'l': 3, 'o': 2, 'h': 1, 'e': 1, ' ': 1, 'w': 1, 'r': 1, 'd': 1})
```

Model - Encoder

- Encoder
 - Embedding Layer + bidirectional RNN layer

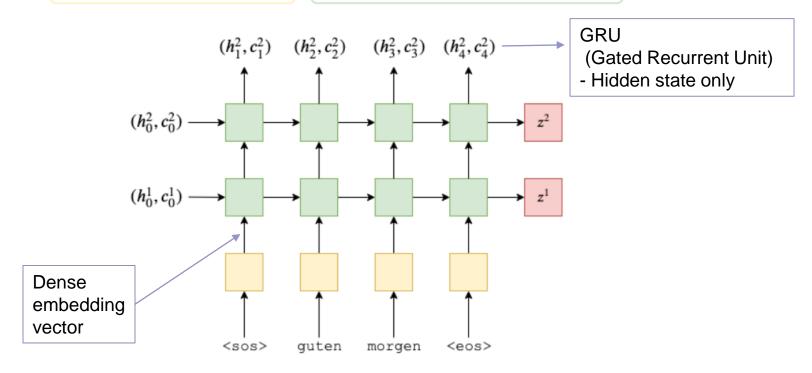




Model - Encoder

Encoder

□ Embedding Layer + bidirectional RNN layer



м

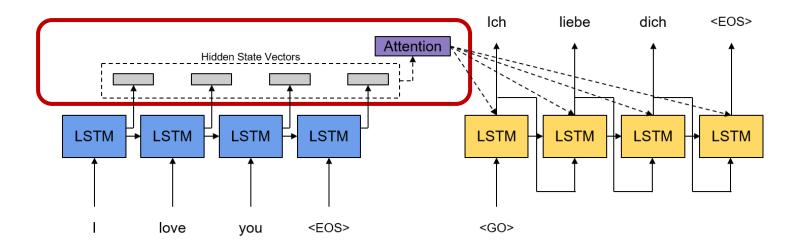
Model - Encoder

```
class Encoder(nn.Module):
  def <u>init</u> (self, input_dim, emb_dim, enc_hid_dim, dec_hid_dim, dropout):
     super().__init__()
     self.embedding = nn.Embedding(input_dim, emb_dim)
     self.rnn = nn.GRU(emb_dim, enc_hid_dim, bidirectional = True)
     self.fc = nn.Linear(enc hid dim * 2, dec hid dim)
     self.dropout = nn.Dropout(dropout)
  def forward(self, src):
                                                            src = [src_len, bs]
                                                            embedded = [src_len, bs, emb_dim]
     embedded = self.dropout(self.embedding(src))
                                                             outputs = [src len, bs, enc hid dim*2]
                                                             hidden = [2, bs, enc_hid_dim]
     outputs, hidden = self.rnn(embedded)
     hidden = torch.tanh(self.fc(torch.cat((hidden[-2,:::], hidden[-1,:::]), dim = 1)))
     return outputs, hidden
```



Model - Attention

Attention



- Fixed source representation is suboptimal
 - → Attention: Focus on different parts of the input

Model - Attention

 $score(s_{i-1}, h_j) = v_a^{\mathsf{T}} \tanh(W_a[s_{i-1}; h_j])$

```
class Attention(nn.Module):
  def __init__(self, enc_hid_dim, dec_hid_dim):
     super().__init__()
     self.attn = nn.Linear((enc_hid_dim * 2) + dec_hid_dim, dec_hid_dim)
     self.v = nn.Linear(dec_hid_dim, 1, bias = False)
  def forward(self, hidden, encoder_outputs):
                                                           hidden.unsqueeze: [bs, 1, dec hid dim]
     batch size = encoder outputs.shape[1]
                                                           hidden.repeat: [bs, src len, dec hid dim]
     src_len = encoder_outputs.shape[0]
                                                           encoder outputs = [src len, bs, enc hid dim*2]
     hidden = hidden.unsqueeze(1).repeat(1, src_len, 1)
                                                                            → [bs, src_len, enc_hid_dim*2]
     encoder_outputs = encoder_outputs.permute(1, 0, 2)
     energy = torch.tanh(self.attn(torch.cat((hidden, encoder outputs), dim = 2)))
     attention = self.v(energy)
     attention = attention.squeeze(2)
     return F.softmax(attention, dim=1)
```

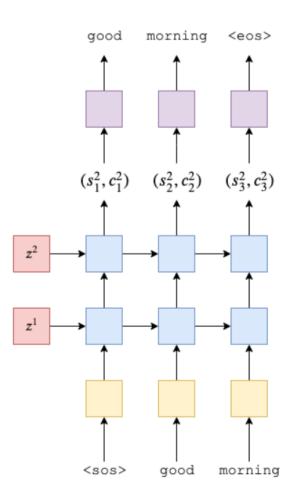
Normalization

Score



Model - Decoder

- Decoder
 - □ previous hidden state + attention + new input→ output
 - Embedding Layer
 - + RNN layer
 - + Fully Connected layer

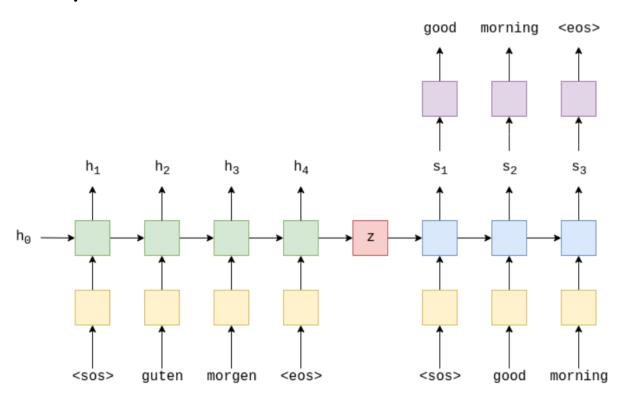


Model - Decoder

```
class Decoder(nn.Module):
  def init (self, output dim, emb dim, enc hid dim, dec hid dim, dropout, attention):
    super().__init__()
    self.output dim = output dim
    self.attention = attention
    self.embedding = nn.Embedding(output_dim, emb_dim)
    self.rnn = nn.GRU((enc hid dim * 2) + emb dim, dec hid dim)
    self.fc_out = nn.Linear((enc_hid_dim * 2) + dec_hid_dim + emb_dim, output_dim)
    self.dropout = nn.Dropout(dropout)
                                                         <br/>
<br/>
bmm:행렬곱>
  def forward(self, input, hidden, encoder_outputs):
                                                         a = [bs, 1, src\_len]
    input = input.unsqueeze(0)
                                                         encoder_outputs = [bs, src_len, enc_hid_dim*2]
                                                         weighted = [bs, 1, enc hid dim*2]
    embedded = self.dropout(self.embedding(input))
    a = self.attention(hidden, encoder outputs)
                                                                    embedded = [1, bs, emb_dim]
                                                                    weighted = [1, bs, dec_hid_dim*2]
    weighted = torch.bmm(a, encoder_outputs)
                                                                    rnn input = [1, bs, emb dim+dec hid dim*2]
    weighted = weighted.permute(1, 0, 2)
                                                                    hidden = [bs, dec hid dim]
    rnn input = torch.cat((embedded, weighted), dim = 2)
                                                                               → [1, bs. dec hid dim]
    output, hidden = self.rnn(rnn input, hidden.unsqueeze(0))
    prediction = self.fc_out(torch.cat((output, weighted, embedded), dim = 1))
    return prediction, hidden.squeeze(0)
```

Model - Seq2Seq

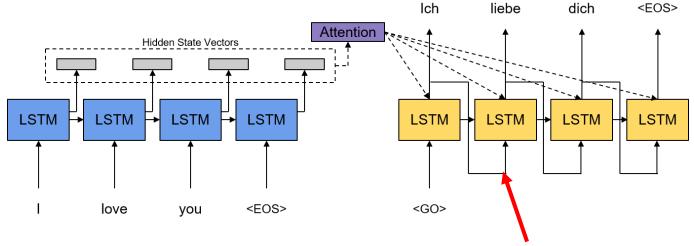
■ Encapsulate Encoder-Attention-Decoder





Model - Seq2Seq

- **Decoder**에서 앞쪽 단어들에 대한 예측이 틀릴 경우, 뒤쪽 단어들에 게 큰 영향
- Training 과정에서 수렴 속도를 느리게 하며, 모델을 불안정하게 만들 수 있음
- Teacher forcing ratio
 - □ training 과정에서, 앞에서 예측한 단어 대신 정답 단어를 입력으로 사용할 확률



Model - Seq2Seq

```
class Seq2Seq(nn.Module):
  def __init__(self, encoder, decoder, device):
    super().__init__()
     self.encoder = encoder
    self.decoder = decoder
    self.device = device
  def forward(self, src, trg, teacher_forcing_ratio = 0.5):
     batch_size = src.shape[1]
    trg_len = trg.shape[0]
    trg_vocab_size = self.decoder.output_dim
     outputs = torch.zeros(trg_len, batch_size, trg_vocab_size).to(self.device)
     encoder_outputs, hidden = self.encoder(src)
     input = trg[0,:]
     for t in range(1, trg_len):
       output, hidden = self.decoder(input, hidden, encoder outputs)
       outputs[t] = output
       teacher force = random.random() < teacher forcing ratio
       top1 = output.argmax(1)
       input = trg[t] if teacher_force else top1
     return outputs
                                               Predicted word
                           True word
```



Model

Initialize & Train

```
INPUT_DIM = len(vocab_en)
DEC DROPOUT = 0.5
enc = Encoder(INPUT_DIM, ENC_EMB_DIM, HID_DIM, N_LAYERS, ENC_DROPOUT)
dec = Decoder(OUTPUT_DIM, DEC_EMB_DIM, HID_DIM, N_LAYERS, DEC_DROPOUT)
model = Seq2Seq(enc, dec, device).to(device)
optimizer = optim.Adam(model.parameters())
TRG_PAD_IDX = new_stoi2['<PAD>']
criterion = nn.CrossEntropyLoss(ignore_index = TRG_PAD_IDX)
def train(model, iterator, optimizer, criterion, clip):
  model.train()
  epoch_loss = 0
  for src, trg in iterator:
      optimizer.zero_grad()
      output = model(src, trg)
  return epoch loss/len(iterator)
```



	1	2	3	4	5
Reference	학생이	인공지능에	관한	수업을	듣습니다
Candidate1	인공지능에	관한	수업을	듣습니다	학생이
Candidate2	학생이	화학에	관한	수업을	합니다

- 학습된 모델의 text generation 성능 평가 방법
 - □ cross-entropy loss는 실제 번역 성능과 완벽히 일치하지 않음
 - □ cross-entropy loss는 위의 예제에서 candidate 2를 더 높이 평가할 수 있음
 - □ 문장 유사도를 측정하기 위한 다른 방법 필요



- n gram Precision = 일치하는 n–gram 수 전체 n–gram 수
- Clipping
 - □ 중복된 n-gram은 true에 있는 count가 최댓값
 - □ Ex) True sentence에 apple이 2 번 있지만 predicted sentence에는 3번 들어가 있을 경우 2번만 인정
- Brevity Penalty

$$\Box BP = \min \left(1, \exp \left(1 - \frac{\text{output length}}{\text{reference length}} \right) \right)$$

BLEU Score

BLEU = BP ×
$$\prod_{n=1}^{4}$$
 (n – gram Precision)^{1/4}

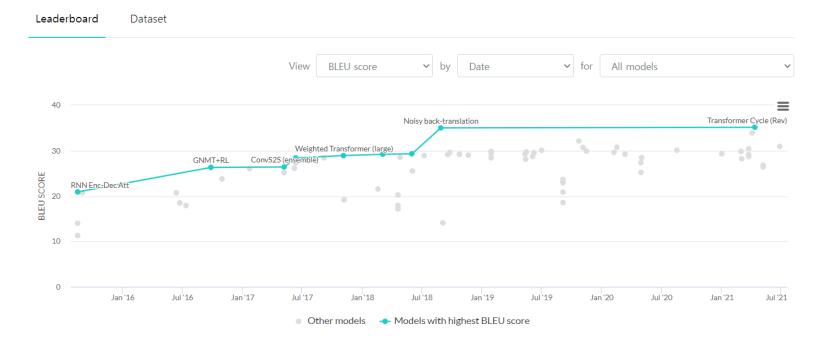


BLEU = BP ×
$$\prod_{n=1}^{4}$$
 (n – gram Precision)^{1/4}

Reference output

- □ 학생이 인공지능에 관한 수업을 듣습니다
- Candidate output
 - □ 어린이 학생이 인공지능에 관한 수업을 수업을 합니다
- $1 \text{gram Precision} = \frac{4}{7}$ [학생이, 인공지능에, 관한, 수업을]
- $2 \text{gram Precision} = \frac{3}{6}$ [(학생이 인공지능에), (인공지능에 관한), (관한 수업을)]
- $3 \text{gram Precision} = \frac{2}{5}$ [(학생이 인공지능에 관한), (인공지능에 관한 수업을)]]
- $4 \text{gram Precision} = \frac{1}{4}$ [(학생이 인공지능에 관한 수업을)]
- $\blacksquare \quad \text{BP} = \min\left(1, \exp\left(1 \frac{7}{5}\right)\right) = 1$
- \blacksquare BLUE = 0.393

- Torchtext.data.metrics.bleu_score (candidate_corpus, references_corpus, max_n, ...)
 - □ candidate_corpus = 점수를 측정할 후보 문장 모음
 - □ references_corpus = 참조할 정답 문장 모음
 - □ max_n = 계산할 최대 n-gram



.

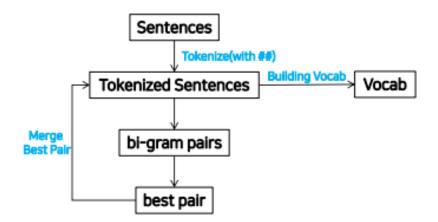
Contents

- Text generation using RNN & Attention
 - Practice
 - Load/preprocess data
 - Build Seq2Seq with attention model
 - □ Encoder
 - Attention
 - Decoder
 - □ Seq2Seq
 - Measure with BLEU
- Subword Tokenization
 - □ BPE (Byte Pair Encoding)
 - WordPiece
 - □ SentencePiece



BPE (Byte Pair Encoding)

- BERT 기반 모델들에 쓰이는 subword tokenization 기법
- OOV(Out-of-Vocabulary) 문제 해결
- Idea: 의미 있는 단위로 단어를 자르자
 - □ 의미 있는 패턴 (subword)는 자주 등장
 - □ 반복되는 패턴은 의미를 가지는 subword일 확률이 높음.



Merge Best Pair - 가장 많이 등장하는 bi-gram pair를 찾아 merge



BPE (Byte Pair Encoding)

- Example: aaabdaaabac
 - □ 1) Vocab: (a, b, c, d) → character 단위
 - □ Tokenize: (a a a b d a a a b a c)
 - □ Bi-gram pairs: (<mark>aa</mark> aa ab bd da <mark>aa aa</mark> ab ba ac)
 - □ 2) Vocab: (a, b, c, d, aa)
 - \Box Tokenizing: (aa a b d aa a b a c) = (X a b d X a b a c)
 - ☐ Bi-gram pairs: (Xa ab bd dX Xa ab ba ac)
 - □ 3) Vocab: (a, b, c, d, aa, ab)
 - \Box Tokenizing: (aa ab d aa ab a c) = (X Y d X Y a c)
 - ☐ Bi-gram pairs: (XY Yd dX XY Ya ac)
 - □ 4) Vocab: (a, b, c, d, aa, ab, aaab)



WordPiece

- **BPE**의 변형 알고리즘
 - □ **BPE:** 빈도수가 가장 높은 쌍을 병합

WPM (Wordpiece Model)

- □ Corpus의 likelihood 를 가장 높이는 쌍으로 결합
- \square P(c1, c2)/P(c1)P(c2)
- □ WPM을 수행하기 이전의 문장:
 - Jet makers feud over seat width with big orders at stake
- □ WPM을 수행한 결과(wordpieces):
 - _J et _makers _fe ud _over _seat _width _with _big _orders _at _stake
- BERT, DistilBERT, Electra



SentencePiece

- 사전 토큰화 작업없이 단어 분리 토큰화 수행
 - □ 중국어, 일본어, 한국어 → pre-tokenization 까다로움
 - □ End-to-end system, Use raw text
 - □ Google에서 공개
 - Normalizer, Trainer, encoder, Decoder
 - □ Normalizer: 의미적으로 동일한 문자들 표준형식으로 정규화
 - □ Trainer: 서브 워드 분절 모델 학습
 - □ Encoder: 학습된 모델을 이용하여 서브워드 나열로 분절
 - □ Decoder: 서브 워드의 나열을 문장형태로 변환
- ALBERT, XLNet, T5