

Lab 5: Generative Models

<삼성 AI 전문가 교육과정> 실습
서울대학교 바이오지능 연구실 (장병탁 교수)
최원석, 김윤성
2022.06.09

Biointelligence Laboratory
Dept. of Computer Science and Engineering
Seoul National University



Generative Models


Generative Models(생성 모델)

■ Discriminative Models (Same as Supervised Learning)

- 데이터 x , 레이블 $y \rightarrow$ 데이터를 받아 레이블을 추측, $P(Y|X)$
- 입력에 대한 레이블의 경계선만 파악하면 충분
- 레이블로부터 다시 데이터를 복구하는 문제 $P(X|Y)$ – 해결이 어려움

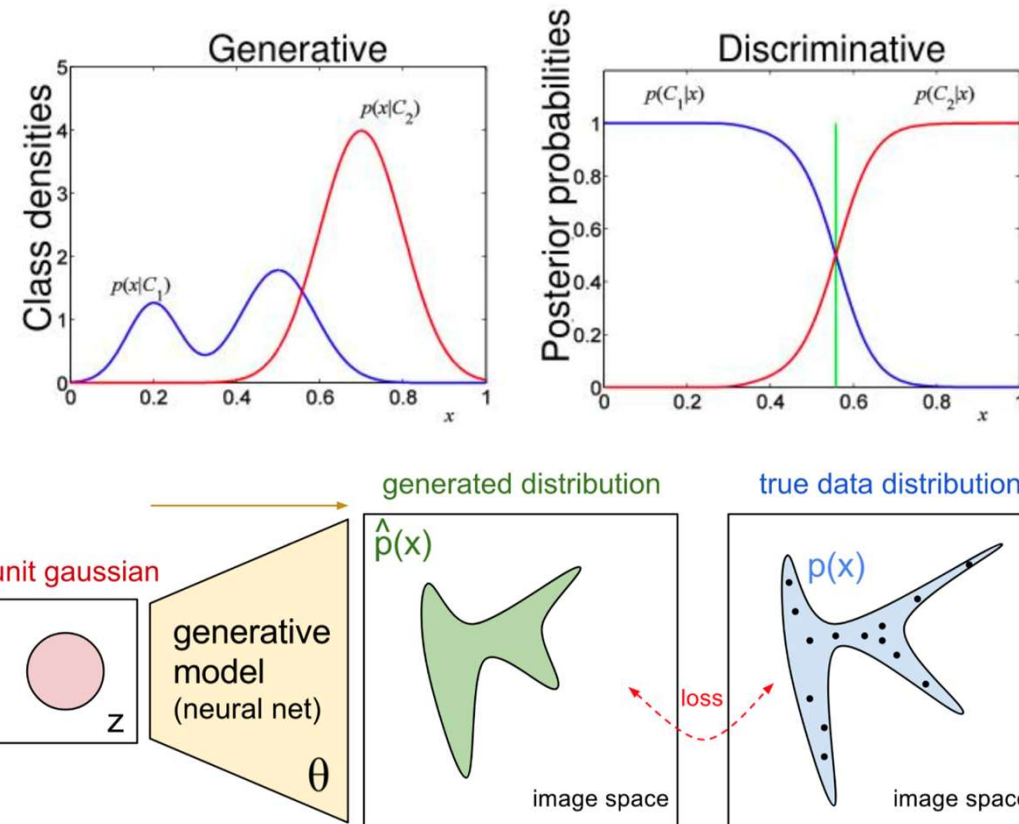
■ Generative Models

- 데이터 생성의 과정: $P(Y) \rightarrow P(X|Y)$
- 실제 데이터의 분포를 토대로 데이터 생성
 - 실제 데이터의 분포를 학습
- 비교적 복잡하고, 실제 현상에 대한 가정이 필요



Generative Models(생성 모델)

- 생성 모델: 몇가지 가정 하에 실제 데이터의 분포를 학습
 - 학습한 데이터의 확률분포로부터 데이터를 생성



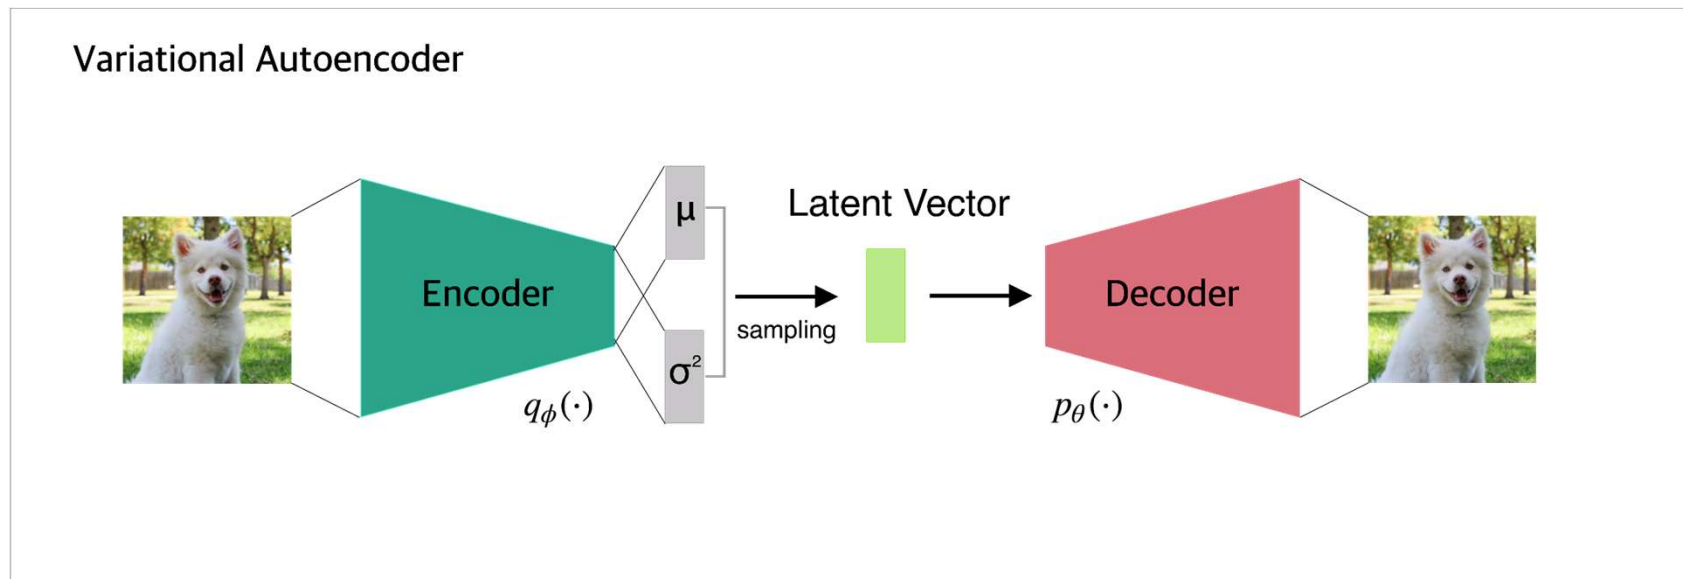
Generative Models(생성 모델)

- 생성 모델의 종류
 - GAN (Generative Adversarial Network)
 - VAE (Variational AutoEncoder)
 - Generative Flow
 - ...
 - Diffusion model : New topic!

Variational Autoencoder

■ VAE

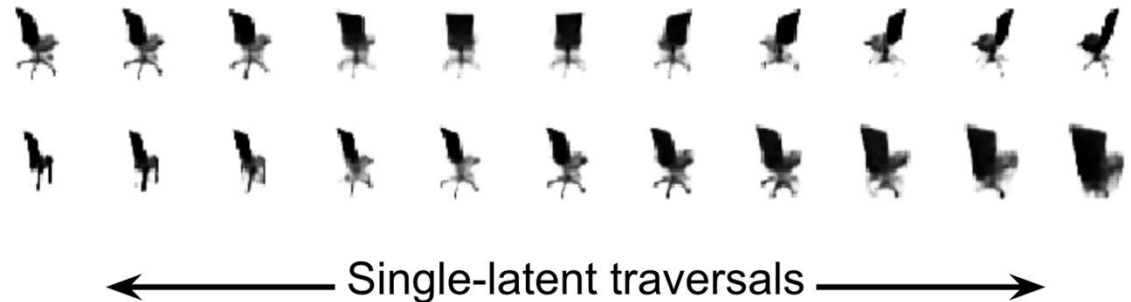

- 이미지를 Latent 공간의 Multivariate Gaussian 분포로 사영
- 사영된 Gaussian 분포에서 샘플링하는 것으로 latent vector를 생성하고 이를 통해 원본 이미지를 재생성



Variational Autoencoder

■ VAE (Cont.)

- 이미지를 Latent 공간의 확률분포로 사영하므로 데이터의 특성이 Latent 공간 상에서 연속적으로 변화
- Beta-VAE : 데이터의 특성이 유의미하게 분류되도록 학습을 유도



Generative Models(생성 모델)

■ 생성모델의 활용

- 데이터의 분포, Representation에 대한 학습
 - “좋은” Representation을 획득할 수 있다면, 이를 통해 다른 문제를 해결하는 데 있어 성능 향상에 도움
 - VAE, beta-VAE ,
- 데이터의 특성을 재조립하여 새로운, 그럴듯한 데이터를 생성
 - GAN, ...

Generative Adversarial Network

Adversarial Networks

■ 대립 신경망(Adversarial Networks)

- 서로 다른 다수의 신경망이 경쟁하면서(적대적으로) 학습하는 방식

■ “Generative” Adversarial Network(GAN)

- 생성 모델(generator)
 - 실제 데이터와 비슷한 데이터를 생성하는 모델
 - 실제 데이터의 분포를 근사 -> 분포에 따른 샘플 반환
- 판별 모델(discriminator)
 - 입력이 실제 데이터인지, generator가 생성한 데이터인지를 판별


각 신경망의 목표

■ Discriminator

- Generator의 생성결과(fake)와 실제 데이터(real)를 제대로 분류하는 것
- $\mathcal{L}_D = -(\log(real) + \log(1 - fake))$
 - $real = D(x) \rightarrow 1, fake = D(G(z)) \rightarrow 0$

■ Generator

- Discriminator를 속이는 것
 - $fake = D(G(z)) \rightarrow 1$



■ Optimization

- $\min_G \max_D (E_{x \sim p_{real}} [\log(D(x))] + E_{z \sim N(0,1)} [\log(1 - D(G(z)))])$

알고리즘

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k , is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

for k steps **do**

- Sample minibatch of m noise samples $\{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$ from noise prior $p_g(\mathbf{z})$.
- Sample minibatch of m examples $\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}\}$ from data generating distribution $p_{\text{data}}(\mathbf{x})$.
- Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(\mathbf{x}^{(i)}) + \log \left(1 - D(G(\mathbf{z}^{(i)})) \right) \right].$$

end for

- Sample minibatch of m noise samples $\{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$ from noise prior $p_g(\mathbf{z})$.
- Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log \left(1 - D(G(\mathbf{z}^{(i)})) \right).$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

Discriminator

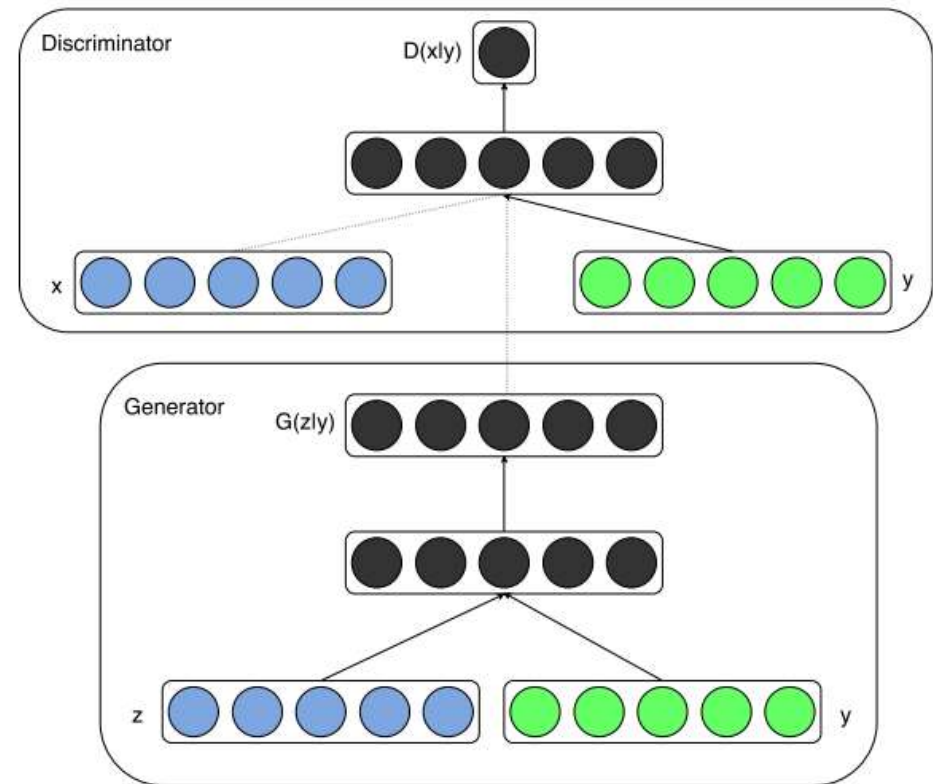
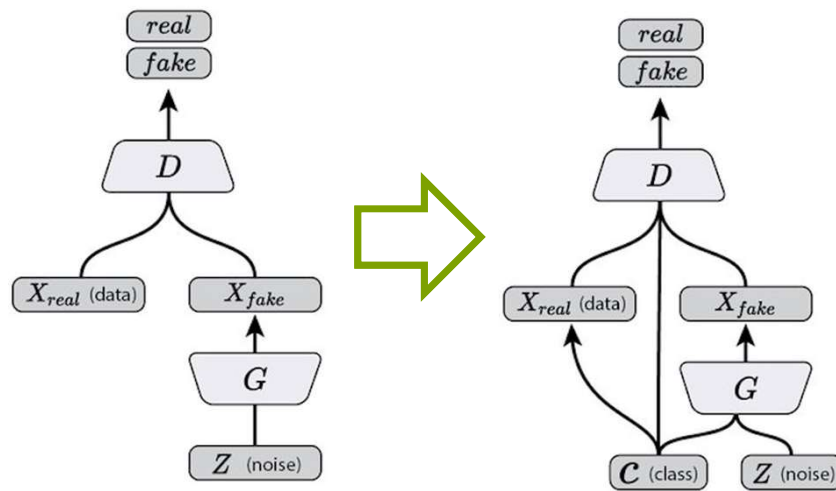
Generator

Conditional GAN (cGAN)

- 가장 기본적인 GAN은 class 정보를 부여하지 않음
 - 숫자 6을 생성하고 싶어도, 명시적으로 6을 생성할 수 없음
 - **Mode collapse** : 학습의 결과로 1만 출력하는 등 생성하기 쉬운 것만 생성
- cGAN – 추가적인 제약 정보를 GAN에 적용
 - Generator, discriminator가 데이터를 생성하고 분류할 때 참고할 정보를 부가적으로 입력
 - 레이블, 특성, feature 등

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x, y)] + E_{z \sim p_z(z)} [\log \{1 - D(G(z, y), y)\}]$$

Conditional GAN (cGAN)



Vanilla GAN의 학습 불안정성

■ Non-convergence

- Generator, discriminator가 번갈아 학습하면서, 파라미터가 수렴하지 않음

■ Mode collapse

- Generator가 모든 data를 생성하는 것이 아닌, 특정 데이터만 생성

■ Diminished gradient

- Discriminator가 generator에 비해 성능이 너무 좋아, generator를 학습시키는 gradient가 0으로 사라짐
- Loss function에 사용되는 distance metric이 부적절하여 의미 있는 gradient를 생성하지 못함

■ Highly sensitive to the hyperparameter selections


GAN zoo

- GAN의 불안정성을 해결하거나 각종 기능을 추가한 모델들의 리스트
 - <https://deephunt.in/the-gan-zoo-79597dc8c347>
 - DCGAN - convolution layer 적용, 가장 기본이 되는 모델
 - Stabilized training – Unrolled GAN, LSGAN, WGAN(-GP), SN-GAN, ...
 - Image translation – Pix2Pix, DiscoGAN, CycleGAN, StarGAN, ...
 - Latent disentanglement – cGAN, InfoGAN, ...
 - Quality - Progressively Growing GANs, BigGAN, ...
 - 등등..

GAN – Cross-domain

■ StarGAN

(a) Cross-domain models



(b) StarGAN

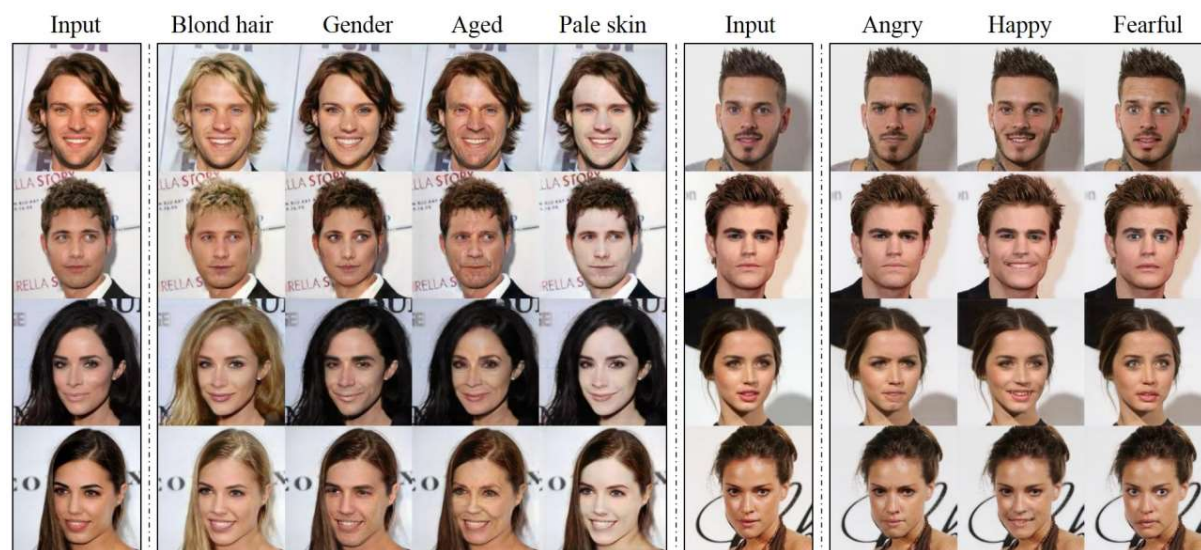



Figure 1. Multi-domain image-to-image translation results on the CelebA dataset via transferring knowledge learned from the RaFD dataset. The first and sixth columns show input images while the remaining columns are images generated by StarGAN. Note that the images are generated by a single generator network, and facial expression labels such as angry, happy, and fearful are from RaFD, not CelebA.

GAN – Super(Hyper) Resolution Image

■ SinGAN




Figure 2: **Image manipulation.** SinGAN can be used in various image manipulation tasks, including: transforming a paint (clipart) into a realistic photo, rearranging and editing objects in the image, harmonizing a new object into an image, image super-resolution and creating an animation from a single input. In all these cases, our model observes only the training image (first row) and is trained in the same manner for all applications, with no architectural changes or further tuning (see Sec. 4).

Codes

- 실습 코드 Github 주소

- https://github.com/yskim5892/AI_Expert_2022